Tutorial Big Data CLEI 2019 Ciudad de Panam



Ciudad de Panamá, Panamá

Por: Edwin Montoya emontoya@eafit.edu.co



Hive y Sqoop Caso de estudio - Amazon EMR — - Amazon RDS / MySQL -

Edwin Montoya – <u>emontoya@eafit.edu.co</u> 2019



Datos y scripts en:

https://github.com/edwinmontoya/tutorialbigdataclei2019.git

Datos específicos:

Github:/datasets/retail_logs/

Amazon S3: s3://emontoyapublic/datasets/retail_logs/

Amazon RDS/MySQL (más adeltante se explica)

Scripts:

Github:/02-hive/case_retail_db* (para Amazon EMR) /rdbms/retail_db* (para Amazon RDS)



Pasos

La empresa

Define las PREGUNTAS DE NEGOCIO

Identificar las fuentes de datos

ETL

Procesamiento - Analítica

Resultado -> Aplicación



La empresa

Es una tienda de venta de artículos deportivos, que tiene tiendas físicas/presenciales, pero que también tiene sitio de ventas por web.

Ej: Nike, Adidas, Sportline, Foot Locker, etc.



Pregunta de Negocio

Son los productos más visitados en el sitio web los más vendidos?

Son los productos más visitados los que hacen parte de los de mayor rentabilidad?



Identificar los datos

¿Dónde están los Datos?

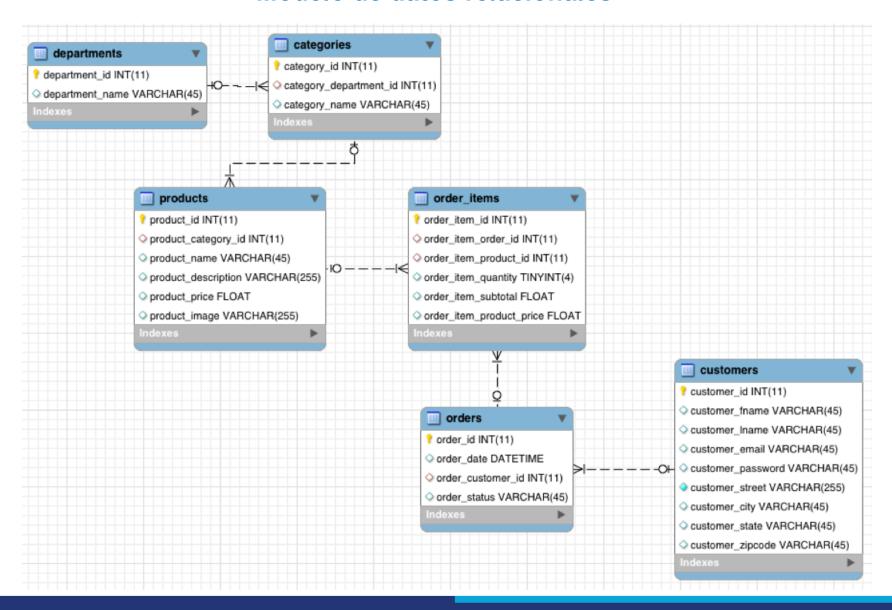
La primera lÍnea de trabajo, son los datos operativos de ventas reales de la compañia de los productos.

Estos datos se encuentran almacenados en RDBMBS, en este caso MySQL. Luego, hay que entender el modelo de datos.

Logs de navegación del sitio principal de comercio electrónico.



Modelo de datos relacionales





Carga de datos al DHW Base de datos Operacionales

Debemos ingestar los datos operacionales de MySQL en HDFS y Hive.

Para ello, utilizamos HUE o sqoop desde Shell

Info de los datos operacionales:

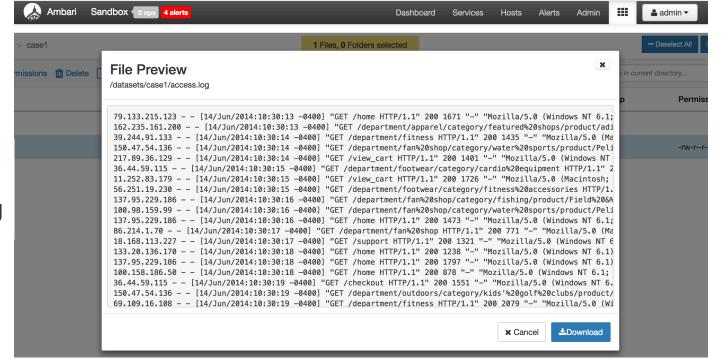
- Base de datos: Amazon RDS/MySql
- IP_server_DB: database-1.cj1yhistqein.us-east-2.rds.amazonaws.com
- Database: retail db
- Username: retail_dba
- Password: retail_dba



TAREA: Carga de datos al DHW Logs de navegación Datasets

File Preview

/datasets/case1/access.log



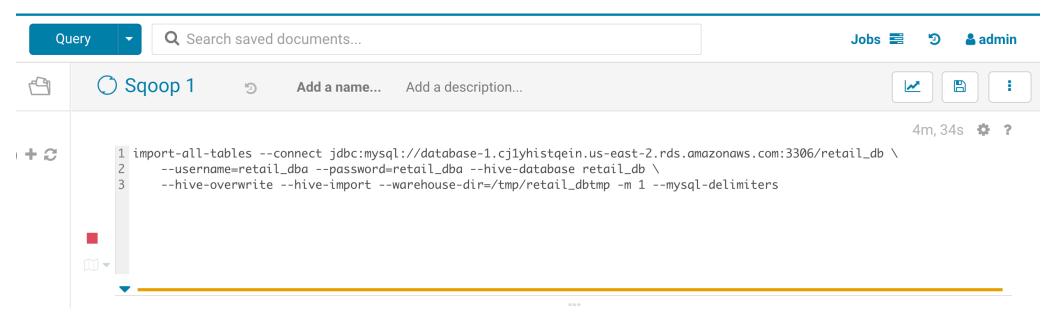


Cargar los datos operacionales

Sqoop import

1. CREA TU PROPIA BASE DE DATOS, Ej: 'emontoyadb' **CREATE DATABASE emontoyadb;** 2. IMPORTA LOS DATOS AL DATALAKE (hdfs y/o Hive) sqoop import-all-tables \ --connect jdbc:mysql:// database-1.cj1yhistqein.us-east-2.rds.amazonaws.com :3306/retail db \ --username=retail dba --password= retail dba \ --hive-database emontoyadb \ --hive-overwrite \ --warehouse-dir=/user/emontoya/retail_db/ \ --hive-import \ --mysql-delimiters -m 1





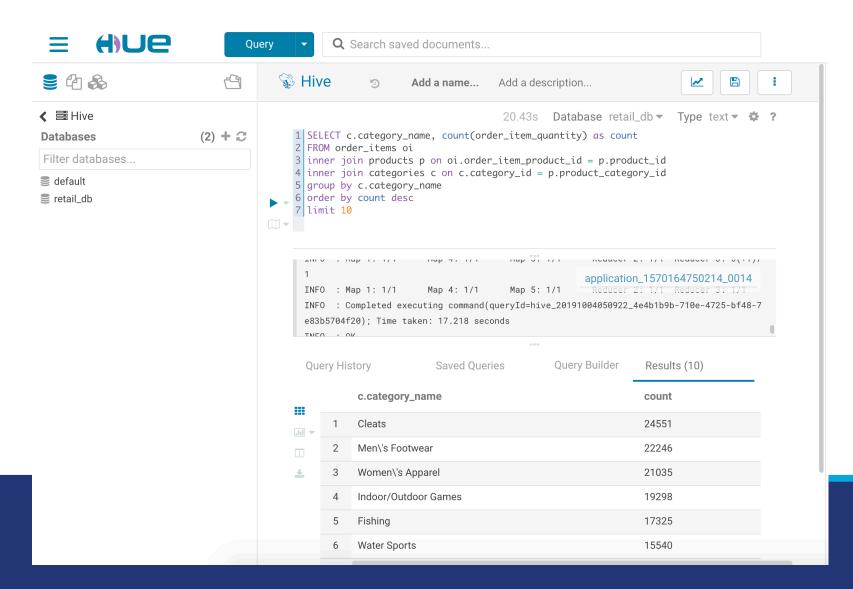


Procesar

Una vez cargados los datos, se procesan con:

Hive:

-- CATEGORIAS MÁS POPULARES DE PRODUCTOS

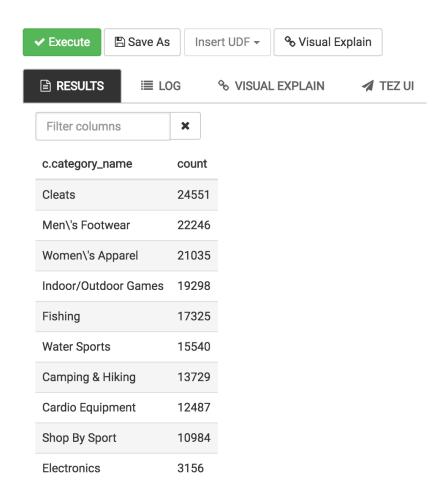




script

```
SELECT c.category_name, count(order_item_quantity) as count FROM order_items oi inner join products p on oi.order_item_product_id = p.product_id inner join categories c on c.category_id = p.product_category_id group by c.category_name order by count desc limit 10;
```



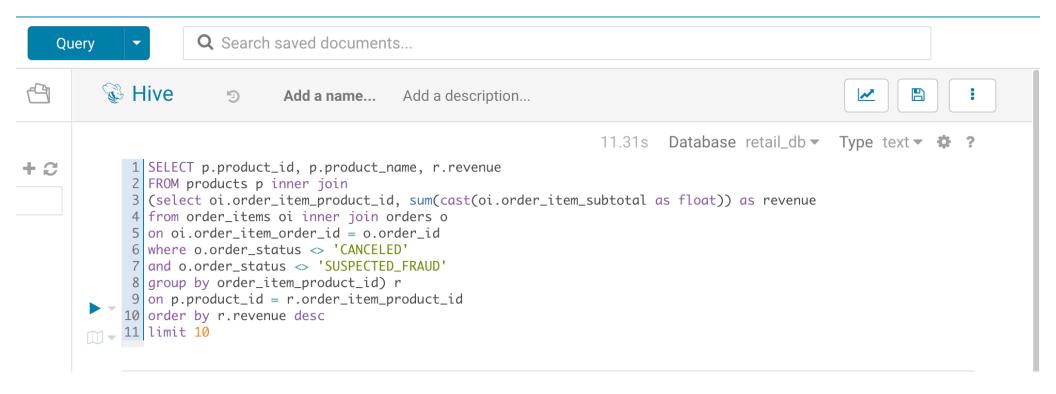


resultado





top 10 de productos que generan ganancias





script

```
SELECT p.product_id, p.product_name, r.revenue

FROM products p inner join

(select oi.order_item_product_id, sum(cast(oi.order_item_subtotal as float)) as revenue

from order_items oi inner join orders o

on oi.order_item_order_id = o.order_id

where o.order_status <> 'CANCELED'

and o.order_status <> 'SUSPECTED_FRAUD'

group by order_item_product_id) r

on p.product_id = r.order_item_product_id

order by r.revenue desc

limit 10;
```



Query History Saved Queries Query Builder Results (10) p.product_name p.product_id r.revenue 1004 Field & Stream Sportsman 16 Gun Fire Safe 6637668.282318115 365 Perfect Fitness Perfect Rip Deck 4233794.3682899475 Diamondback Women\'s Serene Classic Comfort Bi 957 3 3946837.004547119 191 Nike Men\'s Free 5.0+ Running Shoe 3507549.2067337036 502 Nike Men\'s Dri-FIT Victory Golf Polo 3011600 1073 Pelican Sunstream 100 Kayak 2967851.6815185547 1014 O\'Brien Men\'s Neoprene Life Vest 2765543.314743042 8 403 Nike Men\'s CJ Elite 2 TD Football Cleat 2763977.4868011475 Under Armour Girls\' Toddler Spine Surge Runni 627 1214896.220287323 10 565 adidas Youth Germany Black/Red Away Match Soc 63490

resultados



Correlación

Como usted es una persona de datos muy inteligente, se da cuenta de que otra pregunta comercial interesante sería: ¿son los productos más vistos también los más vendidos?



Ingestar, almacenar, y procesar logs de eventos de servidores web.

Una de las tecnologías que se usan para esto es FLUME. Flume es un framework de ingesta en tiempo real hacia HDFS.

Permite enrutar, filtrar, agregar, etc en una plataforma de procesamiento escalable.

Mientras tanto, se cargaran los logs en HDFS y procesaran con Hive

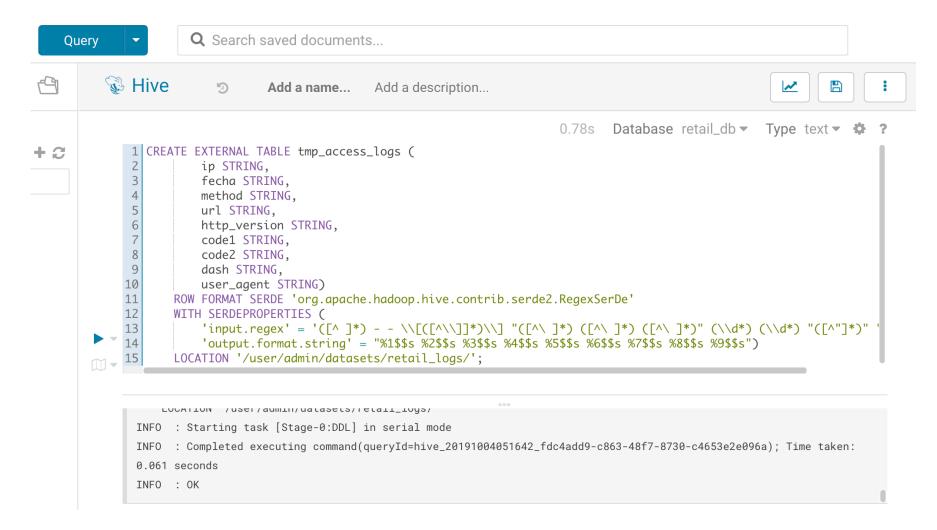


cargar los datos en HDFS en Hive como una tabla externa
Datos previamente cargados en:
/datasets/retail_logs/access.log

- -- CREAR DIRECTORIO PARA TABLA EXTERNA CON ETL
- \$ hdfs dfs -mkdir /user/<username>/warehouse/access_logs_etl



Crear tablas ETL - intermedia





script

```
use <username>;
CREATE EXTERNAL TABLE tmp_access_logs (
   ip STRING,
   fecha STRING.
   method STRING,
   url STRING,
   http_version STRING,
   code1 STRING,
   code2 STRING,
   dash STRING,
   user_agent STRING)
  ROW FORMAT SERDE 'org.apache.hadoop.hive.contrib.serde2.RegexSerDe'
 WITH SERDEPROPERTIES (
   'input.regex' = '([^ ]*) - - \\[([^\\]]*)\\] "([^\ ]*) ([^\ ]*)" (\\d*) (\\d*) "([^"]*)" "([^"]*)",
   'output.format.string' = "%1$$s %2$$s %3$$s %4$$s %5$$s %6$$s %7$$s %8$$s %9$$s")
   LOCATION '/user/<username>/datasets/retail_logs/';
```



Crear tablas ETL - final

```
CREATE EXTERNAL TABLE etl_access_logs (
    ip STRING,
    fecha STRING,
    method STRING,
    url STRING,
    http_version STRING,
    code1 STRING,
    code2 STRING,
    dash STRING,
    user agent STRING)
  ROW FORMAT DELIMITED FIELDS TERMINATED BY ','
  LOCATION '/user/<username>/warehouse/access_logs_etl';
                      Q Search saved documents...
    Query
4
         Hive
                                 Add a name...
                                                Add a description...
                                                                          8.22s
                                                                                  Da
             1
2
3
               CREATE EXTERNAL TABLE etl_access_logs (
+ 2
                       ip STRING,
                       fecha STRING,
             4
                       method STRING,
             5
                       url STRING,
             6
                       http_version STRING,
                       code1 STRING,
                       code2 STRING,
             9
                       dash STRING,
```

user_agent STRING)

ROW FORMAT DELIMITED FIELDS TERMINATED BY ','

LOCATION '/user/admin/warehouse/access_logs_etl/';

10

11

12



Procesar ETL

ADD JAR /usr/lib/hive/lib/hive-contrib.jar;

INSERT OVERWRITE TABLE etl_access_logs SELECT * FROM tmp_access_logs;



Ahora sí, la pregunta de negocio

--- MUESTRE LOS PRODUCTOS MÁS VISITADOS

SELECT count(*) as contador,url

FROM etl_access_logs

WHERE url LIKE '%\/product\/%'

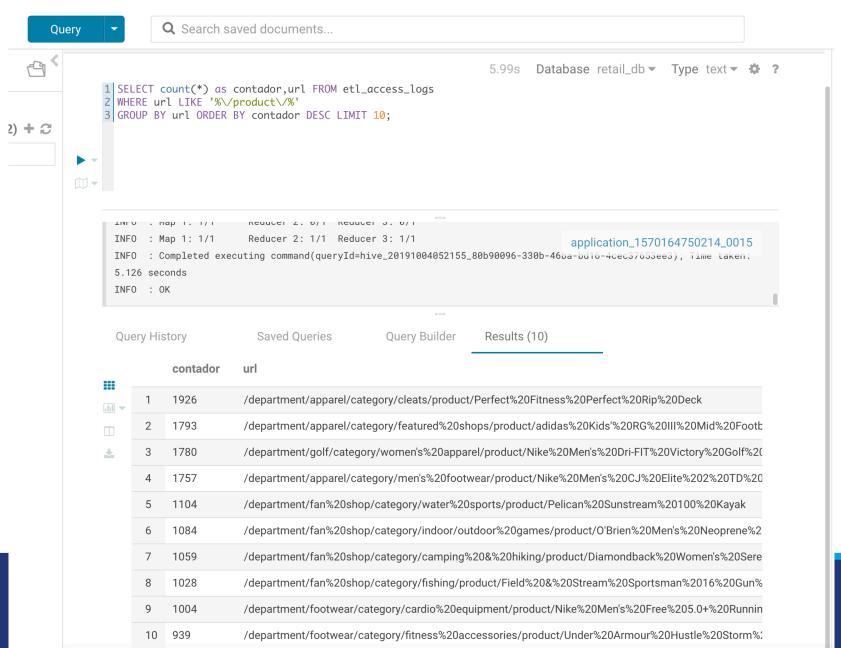
GROUP BY url

ORDER BY contador

DESC LIMIT 10;



Resultados





Conclusiones de analítica de este caso

